



IoT 환경에서의 강화학습을 활용한 우선순위 기반 채널 접근 방안의 최적화

An Optimization of Contention-based Channel Access based on Reinforcement Learning for IoT Environment

저자
(Authors) 김범석
BeomSeok Kim

출처
(Source) [한국정보과학회 학술발표논문집](#) , 2018.12, 1155-1157(3 pages)

발행처
(Publisher) [한국정보과학회](#)
KOREA INFORMATION SCIENCE SOCIETY

URL <http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07613876>

APA Style 김범석 (2018). IoT 환경에서의 강화학습을 활용한 우선순위 기반 채널 접근 방안의 최적화. 한국정보과학회 학술발표논문집, 1155-1157

이용정보
(Accessed) DGIST
114.71.101.***
2019/07/04 13:20 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

IoT 환경에서의 강화학습을 활용한 우선순위 기반 채널 접근 방안의 최적화

김 범 석[○]

경희대학교 컴퓨터공학과

passion0822@khu.ac.kr

An Optimization of Contention-based Channel Access based on Reinforcement Learning for IoT Environment

BeomSeok Kim[○]

Dept. of Computer Engineering, Kyunghee University

요 약

최근 IoT(Internet of Things) 기반의 다양한 응용에 대한 관심이 높아지고 있으며, 이에 따라 상이한 통신기기를 활용한 IoT 서비스 개발에 대한 시도가 다방면에서 이루어지고 있다. 이러한 이기종 IoT 통신 기기간의 통신의 일반적인 통신 성능 요구사항을 충족시키기 위해 일반적으로 경쟁기반의 채널 접근 방안(Contention-based channel access)을 사용하고 있다. 하지만 이기종 통신기기들이 다수 운용되며, 전송 데이터의 패턴이 상이한 IoT 환경에서는 경쟁기반 채널 접근 방안을 사용함에 있어서도 공존성 문제로 인한 성능저하 문제가 야기된다. 본 논문에서는 IoT 통신에서의 전송데이터에 우선순위를 부여하고, 이를 기반으로 채널접근을 할 수 있는 구간, 백오프 타임 선정을 강화학습을 통해 최적화 하여 전송률, 전송성공률, 지연시간 측면에서의 성능향상을 하고자 한다. 제안하는 방안에서의 강화학습은 실제 IoT 기기가 운용되는 시점에 실시간으로 연산하지 않고, 다양한 환경에 대해 충분한 사전 학습을 거친 후, 그 결과를 데이터 테이블화 하여 IoT 기기에 입력하고, 각 IoT 기기는 데이터 테이블을 참조함으로써 학습에 대한 연산 오버헤드를 포함하지 않는 것을 특징으로 한다.

1. 서 론

최근 IoT (Internet of Things)의 확산으로 이를 기반으로 하는 다양한 응용에 대한 관심이 고조되고 있다. 이러한 IoT에 대한 관심의 확산은 실제 구현 관점에서의 IoT 서비스 개발에 대한 시도로 이어지고 있으며, 다양한 IoT 서비스를 개발함에 있어 서비스 목적에 따라 WiFi, Bluetooth, ZigBee, LoRa 등의 다양한 통신기술을 혼용하는 사례가 발생하고 있다[1].

일반적으로 통신 기기의 채널 접근은 비경쟁 기반의 채널 접근과 경쟁기반 채널 접근으로 분류할 수 있다. 비경쟁 기반의 채널 접근 방안은 단일 통신 기술에서의 효율은 좋지만 글로벌 동기화가 요구되며, 외부 간섭에 매우 취약하므로 이기종 통신기기들이 공존하는 상황이 빈번하게 일어나는 IoT 환경에는 적합하지 않다. 따라서 IoT 서비스 구현 관점에서 채널 접근은 상대적으로 동기화가 불필요하며, 간섭에 강한 경쟁기반의 채널 접근 방안을 활용한다.

경쟁기반 채널 접근 방안의 고전은 ALOHA 및 CSMA/CA가 있다. 특히 CSMA/CA는 WiFi, ZigBee 등

WPANs (Wireless Personal Area Networks)의 채널 접근 모드에 사용되고 있으며, 실제 운용되는 통신 기기에서는 CSMA/CA를 기반으로 하는 경쟁기반 채널 접근 방식을 채택하여 사용 중에 있다[2]. 이러한 경쟁기반의 채널 접근 방법에서의 전송률, 지연시간 등의 관점에서 성능을 향상시키고자 하는 기존 연구는 활발히 진행되고 있으며, 특히 최근 인공지능의 핵심기술인 Machine learning, Deep learning, Reinforcement learning 등을 통신 성능 향상을 위해 접목시키고자 하는 시도가 다방면에서 이루어지고 있다[3-5].

Machine learning을 근간으로 하는 Deep learning은 데이터의 분류를 목적으로 사용되며, 구조적으로 큰 차이점을 가지고 있다. 첫 번째로 input layer에서의 pre-processing의 필요 여부이다. Machine learning에서는 input layer와 output layer 사이에 존재하는 hidden layer가 단일 계층을 가지므로, input layer에 입력되는 데이터의 pre-processing이 필수적인 반면, Deep learning의 경우 hidden layer가 다층으로 구성되어 있으며, hidden layer를 거침으로 인해 입력값들의 평가가 일반화 된다는 특징을 가지므로 입력데이터의 pre-processing이 필요가 없다는 장점을 가진다. 이러한 Deep learning의 특징은 성능을 결정하는 상이한 요소가 다층으로 고려되어야 하는 통신 환경에 적합하다는 특징을 가진다. 특히 통신 3계층인 Network layer에서의 routing protocol (경로선택)

* 이 성과는 2018년도 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(No. NRF-2018R1C1B6006938).

및 통신 4계층인 Transport layer에서의 혼잡제어 등의 사례에 많이 활용되고 있다[6-8].

한편, Reinforcement learning은 Deep learning과는 달리 학습 결과에 reward를 부여하여 재학습을 시킴으로써 near-optimal한 값을 도출하는 응용에 많이 활용되는 기술이다. 이는 앞서 언급한 Machine learning 및 Deep learning과는 달리 통신 2계층인 MAC protocol의 parameter 최적화에 활용되고 있다[9-12].

이와 같은 인공지능의 핵심기술인 learning 기술을 접목한 통신 상위계층 성능향상의 시도는 최근 이루어지고 있다. 하지만 다양한 요소를 고려하여 learning을 수행하는데 있어 많은 양의 컴퓨팅 자원과 시간이 필요하며, 이는 실시간으로 환경이 변화되는 통신 환경에는 적합하지 않다. 또한, IoT 환경은 저사양부터 고사양까지 다양한 기기들로 구성되어 있으며, 저사양 IoT 기기에서는 이러한 learning 알고리즘을 수행할 수 없다는 문제가 있다.

본 논문에서는 앞서 언급한 IoT 환경에서의 learning 알고리즘 수행의 문제점을 보완하고, IoT 환경에서의 데이터 중요성을 기반으로 우선순위 기반의 채널 접근 제어 방안을 Reinforcement learning을 활용하여 제안하고자 한다. 제안하는 방안은 기존의 CSMA/CA 기법의 성능을 향상시킴과 동시에 learning 알고리즘 수행에 필요한 컴퓨팅 오버헤드 문제를 해결할 수 있다는 장점을 가진다.

2. 제안하는 방안

본 논문에서 제안하는 방안은 기존 연구인 WBAN 환경에서의 우선순위 기반 채널 접근 방안[13]을 상이한 통신기기들이 공존하는 IoT 환경으로 확장하고, 이를 Reinforcement learning 기법을 통해 최적화하는 것을 목적으로 한다.

2.1. 기존연구: WBAN 환경에서의 우선순위 기반 채널 접근 방안

앞서 언급한 것과 같이 본 논문에서 제안하는 방안은 기존 연구인 IoT 환경과 유사한 무선 인체영역 통신인 WBAN 환경에서의 우선순위 기반 채널 접근 알고리즘을 확장한다. 기존 방안은 좁은 지역에 다수의 기기가 공존하는 WBAN 환경을 고려하고 있으며, 전송반경이 겹치는 통신 기기들의 채널 접근에 있어 발생하는 복잡도(complexity)를 데이터 우선순위에 따라 서로 다른 시간에 접근할 수 있도록 함으로써 채널 접근 복잡도를 경감시켜 성능을 향상시키는 방안이다. 그림 1은 기존 연구의 채널 접근 복잡도를 경감시키는 방안의 구조이다. network coordinator는 네트워크를 구성하는 모든 노드의 데이터 특성을 기반으로 우선순위를 4개의 단위로 나누




그림 1. 제안하는 알고리즘을 적용한 예

Figure 1. An Example of proposed algorithm

며, 각 우선순위에 해당되는 기기들로부터 이전 비콘 구간동안 수집된 패킷의 양을 기반으로 현재 비콘 주기에서의 sub-phase의 시간을 계산한다. 각 sub-phase은 접근을 허용하는 우선순위를 차등적으로 적용하며, 우선순위가 높은 기기일수록 경쟁에 참여할 수 있는 시간을 길게 확보할 수 있어 높은 우선순위에 해당되는 기기의 데이터 전송의 신뢰성을 보장한다. 또한, 동일 시간에 채널에 접근하고자 하는 기기의 수를 절대적으로 줄일 수 있으므로, 채널 접근시 오류율(충돌률)을 줄이고 back-off 시간을 줄일 수 있으므로 높은 전송률을 보장한다.

하지만 기존의 연구에서는 단순히 이전 비콘 구간에 수집된 패킷의 양으로 현재 비콘 주기에서의 sub-phase를 결정하고 있으므로 다양한 네트워크 요소를 고려하지 못한다는 문제를 가지고 있다. 또한, backoff 시간의 결정도 기존의 IEEE 802.15.4에서의 slotted-CSMA/CA의 알고리즘을 그대로 적용하고 있으므로 경쟁에 참여하는 노드의 수에 따른 back-off 시간의 최적화가 이루어지지 않는다는 문제를 가진다.

2.2. 제안하는 방안

제안하는 방안은 위에서 언급한 기존 연구의 문제점을 보완하고, 다양한 네트워크 정보를 기반으로 Reinforcement learning 기법을 활용하여 near-optimal한 MAC 프로토콜의 parameter를 도출하여 적용함으로써 통신 성능을 향상시키고자 한다.

먼저 WBAN의 경우는 coordinator를 중심으로 extended star topology를 구성하여 동작하는 반면 IoT 환경은 이기종 통신기기들이 분산된 환경에서 동작하므로 제안하는 방안은 기존 연구와는 달리 분산 환경에서 동작하는 것을 가정한다. 각 통신 기기는 사전에 각 상황별로 2계층에서 자체적으로 수집할 수 있는 collision ratio, throughput, backoff time 뿐만 아니라 1계층 정보인 path loss, SINR (Signal to Interference and Noise Ratio), signal attenuation를 입력값으로 취하는 Deep

reinforcement learning의 결과값을 데이터 테이블화 하여 가지고있으며, 각 상황에서 가장 좋은 결과값을 가지는 backoff time, sub-phase의 offset을 설정하여 선택하여 동작한다. 이를 위해 기존 연구에서 다른 시뮬레이션 결과를 기반으로 Deep reinforcement learning을 실행하며, 이때 reward는 throughput, collision ratio, power consumption 세 가지를 각각 도출하여 적용한다.

3. 결론 및 향후 계획

본 논문에서는 최근 다양한 방법에 적용 및 활용되고 있는 인공지능의 핵심기술인 Reinforcement learning 기법을 적용한 IoT 환경에서의 우선순위 기반 채널 접근 방안을 제안한다. 제안하는 방안은 기존 연구의 확장 및 최적화를 목적으로 하고 있다. 향후 연구에서는 제안하는 방안을 시뮬레이션으로 개발하고, 이를 실제 sensor node에 구현하여 성능평가를 수행할 예정이다. 또한, IoT 환경에서 발생할 수 있는 공존 상황을 이동성 및 통신기기의 밀집도에 따라 분류하는 방안을 추가로 논의할 예정이며, 이를 기반으로 각 상황에 맞는 최적화된 채널 접근 방안을 선택하여 네트워크 전체의 성능을 향상시킬 수 있는 방안을 연구할 예정이다. 본 연구 및 향후 연구를 통해 통신 상위계층에서의 인공지능 기법 적용의 새로운 연구 접근방법을 제시할 수 있을 것으로 기대하며, 실제 구현관점에서의 통신 성능을 최적화할 수 있을 것이다.

참 고 문 헌

- [1] A. Whitmore, A. Agarwal, and L. D. Xu, "The Internet of Things—A survey of topics and trends," *Information Systems Frontiers*, Vol. 17, Iss. 2, pp. 261-274, April 2015.
- [2] M. Ma and Y. Yang, "A Novel Contention-based MAC Protocol with Channel Reservation for Wireless LANs," *IEEE Trans. on Wireless Communications*, Vol. 7, Iss. 10, pp. 3748-3758, Oct. 2008.
- [3] G. Hinton, L. Deng, D. Yu, et al., "Deep neural networks for acoustic modeling in speech recognition," *IEEE Signal Process. Mag.*, vol. 29, no. 6, pp. 82-97, Nov. 2012.
- [4] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Image Net classification with deep convolutional neural networks," *In Proc. the 25th International Conference on Neural Information Processing Systems (NIPS 2012)*, vol. 1, Lake Tahoe, Nevada, USA, pp. 1097-1105, Dec. 2012.
- [5] M. Helmstaedter, K. L. Briggman, S. C. Turaga, V. Jain, et al., "Connectomic reconstruction of the inner plexiform layer in the mouse retina," *Nature*, vol. 500, no. 7461, pp. 168-174, Oct. 2014.
- [6] T. Hu and Y. Fei, "QELAR: A machine-learning-based adaptive routing protocol for energy-efficient and lifetime-extended underwater sensor networks," *IEEE Trans. Mobile Comput.*, vol. 9, no. 6, Jun. 2010, pp. 796-809.
- [7] B. Mao, Z. M. Fadlullah, F. Tang, N. Kato, et al., "Routing or computing? The paradigm shift towards intelligent computer network packet transmission based on deep learning," *IEEE Trans. Comput.*, vol. 66, no. 11, Nov 2017, pp. 1946-1960.
- [8] Y. Lee, "Classification of node degree based on deep learning and routing method applied for virtual route assignment," *Ad Hoc Netw.*, vol. 58, pp. 70-85, Apr. 2017.
- [9] U. Challita, L. Dong, and W. Saad, "Deep learning for proactive resource allocation in LTE-U networks," *in Proc. 23th European Wireless Conference (European Wireless 2017)*, Dresden, Germany, pp. 1-6, May 2017.
- [10] Z. Xu, Y. Wang, J. Tang, J. Wang, and M. C. Gursoy, "A deep reinforcement learning based framework for power-efficient resource allocation in cloud RANs," *in Proc. 2017 IEEE International Conference on Communications (ICC 2017)*, Paris, France, pp. 1-6, May 2017.
- [11] J. Wang, J. Tang, Z. Xu, Y. Wang, et al., "Spatiotemporal modeling and prediction in cellular networks: A big data enabled deep learning approach," *in Proc. IEEE Conference on Computer Communications (INFOCOM 2017)*, Atlanta, GA, USA, pp. 1-10, May 2017.
- [12] L. Liu, Y. Cheng, L. Cai, S. Zhou, Z. Niu, "Deep learning based optimization in wireless network," *in Proc. 2017 IEEE International Conference on Communications (ICC 2017)*, Paris, France, pp. 21-25, May, 2017.
- [13] 김범석, 조진성, "의료용 WBAN 환경에서 경쟁기반의 MAC 프로토콜을 위한 우선순위 기반 채널 접근 알고리즘," *한국정보과학회논문지:정보통신*, Vol. 30, No. 5, pp. 276-285, 2013.