



강화학습으로 최적화된 합성곱 신경망을 이용한 로터시스템 진단 기술 개발

Health Diagnosis Method for Rotor Systems Using Optimized Convolutional Neural Networks with Reinforcement Learning

저자
(Authors) 공헌배, 정준하, 김명연, 고진욱, 윤병동
Hyeon Bae Kong, Joon Ha Jung, Myungyon Kim, Jin Uk Ko, Byeng D. Youn

출처
(Source) [대한기계학회 춘추학술대회](#) , 2018.12, 183-187(5 pages)

발행처
(Publisher) [대한기계학회](#)
The Korean Society of Mechanical Engineers

URL <http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07606959>

APA Style 공헌배, 정준하, 김명연, 고진욱, 윤병동 (2018). 강화학습으로 최적화된 합성곱 신경망을 이용한 로터시스템 진단 기술 개발. 대한기계학회 춘추학술대회, 183-187

이용정보
(Accessed) DGIST
114.71.101.***
2019/07/04 13:40 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

강화학습으로 최적화된 합성곱 신경망을 이용한 로터시스템 진단 기술 개발

공현배[†], 정준하^{*}, 김명연^{*}, 고진욱^{*}, 윤병동^{**}

Health Diagnosis Method for Rotor Systems Using Optimized Convolutional Neural Networks with Reinforcement Learning

Hyeon Bae Kong, Joon Ha Jung, Myungyon Kim, Jin Uk Ko and Byeng D. Youn

Key Words: Reinforcement Learning(강화학습), Convolutional Neural Networks(합성곱 신경망), Journal Bearing Rotor System (저널베어링 회전체 시스템), Health Diagnosis(건강성 진단), Deep Learning(딥러닝)

Abstract

Journal bearing is a mechanical component used in systems that require high reliability like power plant. It is essential to develop a diagnosis model that can accurately diagnose the state of a journal bearing rotor system because journal bearing's fault can cause enormous economic losses. Generally, fault diagnosis model is developed using data-driven methods to extract features which considered the domain knowledge of the system. However, since the features are domain-dependent, high diagnosis performance cannot be guaranteed reliable. Recently, deep learning-based diagnosis method, which extracts features autonomously is used to solve these problems. Instead of using the deep neural architecture optimized for data, we use existing known models or model architectures selected intuitively. The unoptimized architecture can deteriorate the performance of the fault diagnosis. To solve these problems, we used reinforcement learning to find an optimized architecture iteratively. The results showed higher diagnosis accuracy compare to the state of the art model, the neural architecture search network.

1. 서 론

저널 베어링은 스팀 터빈과 같이 높은 부하 및 속도에서 운동하여 높은 신뢰도를 필요로 하는 시스템에 자주 이용되는 기계요소이다. 이러한 저널 베어링이 고장 났을 때 시스템 전체에 영향을 미치며, 이는 막대한 손실로 이어질 수 있다. 이러한 문제를 해결하기 위해, 기계시스템의 건강성을 진단하는 모델을 개발하여 손실을 최소화하는 연구가 현재까지 진행되고 있다.

진단모델은 물리 기반과 데이터 기반 방식이

[†]학생회원, 서울대학교 기계항공공학부

E-mail : vividsunmi@snu.ac.kr

TEL : (02)883-1664

^{*} 서울대학교 기계항공공학부

^{**} 서울대학교 기계항공공학부, ㈜원프레딕트

있는데, 일반적으로 데이터 기반 방법(Data-Driven Method)을 주로 사용된다. 기존 데이터 기반 방법은 진단하고자 하는 시스템의 도메인 지식을 충분히 쌓고, 쌓은 지식을 이용하여, 도메인에 종속적인 특성 인자를 추출, 이를 이용해서 시스템의 건강성을 진단하였다. 하지만, 도메인에 종속적인 문제를 갖고 있어 다른 도메인으로 확장이 어렵고, 추출한 특성 인자를 재사용하지 못하는 측면에서 매우 비효율적이며, 또한 높은 진단 정확도를 보장하지 못한다. 이러한 문제를 해결하기 위해, 주어진 데이터를 학습하여, 자동적으로 특성 인자 추출과 건강성 진단까지 해주는 딥러닝 기반의 진단모델 개발 연구가 진행되고 있다 [1].

높은 진단 정확도를 얻기 위해, 신경망(Neural Networks)의 구조를 데이터에 적합하게 설계해야 하지만, 일반적으로 잘 알려진 모델을 이용하거나

직관에 의존하여 새로운 모델을 만든다. 하지만, 데이터에 최적화되지 않은 구조는 고장진단 성능을 악화시킨다.

본 연구에서는, 이러한 문제를 해결하기 위해, 자동적으로 신경망의 구조가 try-and-error 를 통해 데이터에 적합한 깊은 신경망을 찾아갈 수 있도록, 강화학습을 이용하였다. 재귀 신경망(Recurrent Neural Networks)을 이용하여 신경망 생성기(Neural Networks Generator)를 도입하였고, 평가 셋(Validation Set)에 대한 정확도를 신경망 생성기의 보상(Reward)으로 하여, 결과적으로 더 높은 정확도를 갖는 신경망 생성기를 얻을 수 있다 [2]. 직관에 의존하지 않은 신경망 설계를 위해, 신경망의 구조까지 학습할 수 있도록 강화학습이란 개념을 도입하였으며, 기존의 최적화되지 않은 구조와 강화학습을 이용해 최적화된 구조의 성능 비교를 통해 제시한 방법의 타당성을 검증하였다.

2. 방 법

2.1 연산 구성요소

합성곱 신경망 구조에는 다양한 종류의 초매개변수(hyper parameter)가 존재한다. 그 예로, 합성곱 계층(Convolution Layer)의 종류, 필터(Filter)의 크기, 연산의 방법, 생략 연결(Skip Connection)의 조합과 위치, 활성화 함수, 계층의 깊이 등이 있다. 이 모든 것을 고려하여 합성곱 신경망을 학습하는 경우, 탐색 공간(Search Space)이 넓어져 거대한 컴퓨팅 자원이 없는 한, 학습을 시키는데 많은 어려움이 존재한다. 따라서, 효율적인 탐색 공간 구성을 위해 모든 계층의 초매개변수를 고려하지 않고, 기존의 연구를 참고하여 일부 계층만을 고려하였다.

우선 계층을 이루고 있는 블록(Block)을 정의하였으며, 블록은 2개의 계층과 두 계층의 연산 그리고 각 계층에 입력으로 어떠한 상태(State)를 연결할지 결정하는 생략 연결이 존재한다. 블록의 집합인 셀(Cell)을 기능에 따라 합성곱 계층 역할을 하는 합성곱 셀(Convolution Cell)과 풀링 계층 역할을 하는 축소 셀(Reduction Cell)로 분류하고, 합성곱 셀과 축소 셀을 탐색한 후 이 합성곱 셀과 축소 셀을 반복적으로 구성하여 신경망 구조를 설계한다.

2.1.1 합성곱 계층

합성곱 계층은 완전 연결 계층(Fully Connected Layer)과 비교해서, 데이터의 인접한 정보들의 상관관계(Covariance)를 비선형 필터를 통하여 국소적인 특성인자를 추출해내는 Locality한 특징을 가진다. 이러한 합성곱 계층을 깊이 쌓는다면, 데이터의 전역 특성인자(Global Features)를 추출해 낼 수 있다. 합성곱의 필터는 가중치를 공유하면서 특성인자의 맵(Feature Maps) 전체에 반복적으로 같은 연산을 하면서, 학습 해야 할 매개변수(Parameters)를 줄일 수 있으며, 토폴로지(Topology)에 강건한 특성인자를 추출할 수 있다. 또한 필터의 크기에 따라서, 특성인자를 추출해야 할 국소적인 범위를 설정할 수 있다.

하지만 작은 필터만을 이용하면, 국소적인 정보에서 비교적 넓게 분포하는 특성인자를 잡아낼 수 없다. 따라서, 큰 필터와 작은 필터를 동시에 사용해야 하는데, 큰 필터를 사용할 경우, 학습해야 할 매개 변수의 수가 많아지며, 이는 과적합(Overfitting)의 문제를 야기하여 성능을 악화시킬 수 있다. 이러한 문제를 해결하기 위해, 대부분의 연구는 직관에 의존하여 필터의 크기를 구성하였다. 또한 합성곱 계층의 채널 단위에서도 문제가 발생한다. 일반적인 합성곱 신경망은 죽은 채널(Dead Channel)이 많이 존재하고, 또한 채널(Channel) 간 상관관계(Correlation)가 낮아, 불필요한 가중치와 연산이 발생하며, 일종의 노이즈처럼 작용하여 성능을 악화시킬 수 있다.

이러한 문제를 해결하기 위해, 점 간 합성곱(Pointwise Convolution), 그룹 합성곱(Grouped Convolution), 팽창 합성곱(Dilated Convolution), 깊이 간 합성곱(Depthwise Convolution), 분리 된 깊이 간 합성곱(Depthwise Separable Convolution)과 같은 다양한 합성곱 계층이 나오게 되었다. 다양한 합성곱의 연구를 통해 필터가 죽지 않음은 물론 채널 간 높은 상관관계를 가질 수 있는 필터를 이용해 효율적으로 전역 특성인자를 추출해낼 수 있다.

하지만, 다양한 합성곱 계층을 고려해야 한다면 탐색 공간이 커지는 문제점이 생긴다. 효율적인 탐색 공간을 구성하기 위해, 분리된 깊이 간 합성곱만을 이용하였다. 필터의 크기도 3 과 5 두 가지 만을 고려하였다. 보폭(Stride)은 합성곱 셀에서는 1의 크기를 사용하였으며, 축소 셀에선

채널 간 겹침 연산의 위치에 따라 1 혹은 2의 크기를 사용하였다.

2.1.2 항등 활성화함수(Identity Activation)

합성곱 신경망은 잔차 신경망(Resnet)이 나오기 전까지, 계층이 깊어질 수록 오히려 성능이 하락했다. 잔차신경망에서는, 항등 생략 연결(Identity Skip Connection)을 이용해 차이를 학습하며, 입력 층이 출력 층에 연결이 되기 때문에, 매개변수의 증가는 없으며, 연산적으로 덧셈만 늘어난다. 또한, 생략 연결으로 인해 순전파(Forward)의 경로가 단순해지며, 이로 인해 역전파(Backward)의 경로도 마찬가지로 단순해져 계층이 깊어져도 학습이 안정적으로 진행되었다. 따라서 이러한 효과를 얻기 위해, 항등 활성화 함수를 연산의 구성요소로 선택하였다. 생략 연결은 결합 연산에서 사용하여, 잔차 신경망의 항등 생략 연결 개념을 사용하였다.

2.1.3 풀링 계층(Pooling Layer)

풀링 계층은 입력 데이터의 변화에 강건한 특성인자 추출을 위해 사용되는데, 일반적으로 평균 풀링(Average Pooling)과 최대 풀링(Max Pooling)이 대표적으로 사용된다. 평균 풀링은 선택된 윈도우 영역의 값을 평균하고, 최대 풀링은 최대값만 선택하는 기법이다. 학습해야 할 매개변수가 없고, 채널 방향으로 독립적으로 연산을 수행한다. 평균 풀링과 최대 풀링 모두 단점이 존재하는데, 평균 풀링의 경우는 강한 자극의 영향이 줄어드는 효과가 발생하고, 최대 풀링은 데이터에 과적합되기 쉽다. 따라서 최대 풀링과 평균 풀링 둘 다 연산의 구성요소 사용하였으며, 합성곱과 마찬가지로 다양한 크기의 풀링을 사용하여 강화학습을 이용해 최적화를 하였을 때, 대부분의 윈도우 크기가 3이었기 때문에, 효율적인 탐색 공간을 위하여 크기가 3인 윈도우만을 고려하였다. 따라서 윈도우 크기가 3인 평균 풀링과 최대 풀링을 연산의 구성요소로 사용하였고, 보폭은 합성곱 계층과 마찬가지로 합성곱 셀에서는 크기가 1이며, 축소 셀은 출력 전 채널 간 겹침 연산의 위치에 따라 크기 1 또는 2의 크기를 갖는 보폭을 사용하였다.

2.1.4 결합 연산(Operation)

일반적으로 결합 연산은 요소 별 더하기 연산(Element-Wise Add) 및 채널 별 겹침 연산(Channel-Wise Concatenation)을 일반적으로 사용한다. 일반적으로 최적화 했을 때, 요소 별로 더하는 연산이 대부분 사용되기 때문에 더하기 연산만 사용하였다. 또한 계층의 깊이에 강건한 학습을 위해 생략 연결을 효과적으로 사용하기 위해서, 숨겨진 상태(Hidden State)에서 각 연산으로의 연결은 이전의 숨겨진 상태와 현재 블록의 입력인 현재의 숨겨진 상태 둘 중에서 선택하도록 하였다. 또한 각 블록에 요소 별 더하기 연산된 결과 값도 각 연산에 연결 될 수 있다. 축소 셀에선 블록 간 순차적인 연결이 되면 4배 축소가 되기도 하며, 차원이 맞지 않게 되기 때문에 연산을 할 수 없게 된다. 이러한 경우를 대비하여, 직접적으로 연결되어 있는 블록의 경우만 보폭을 2로 하고, 나머지 블록은 보폭을 1로 설정한다. 마지막으로, 남은 모든 블록의 출력 값인 요소 별 더하기 연산을 하고 난 후의 값 간의 겹침 연산을 한 후, 점 별 합성곱을 출력으로 한다.

2.2 장단기 기억신경망(LSTM)을 이용한 신경망 생성기

장단기 기억신경망은 연속적인 데이터를 처리할 때 많이 사용하는 신경망이다. 우리가 생성하고자 하는 합성곱 신경망의 구조는 순차적(Sequential)으로 이루어져 있으며, 따라서 합성곱 신경망의 매개변수는 연속적인 데이터를 처리하는 알고리즘을 사용하면 효과적이다. 일반적으로 연속적인 데이터를 학습할 때는 재귀 신경망을 많이 이용하는데, 숨겨진 상태의 값이 이전 숨겨진 상태의 값과 입력 값에 의해 결정되기 때문에 짧은 시간 스텝(Time Step)에 의해 영향을 많이 받는다. 따라서 긴 시간 스텝이 지났을 때, 과거의 데이터는 기억하지 못하는 현상이 발생하며, 또한 긴 시간 스텝이기 때문에 매우 깊은 신경망에 의해 사라지는 기울기 현상(Vanishing Gradient) 발생하여, 학습이 잘 되지 않는다. 이러한 문제를 해결하기 위해, 장단기 기억신경망이 고안되었으며, 이는 숨겨진 상태 이외에 장단기 기억을 위한 셀 상태(Cell State)를 추가한 구조를 갖는다. 따라서 각 셀의 출력은 숨겨진 상태 값과 셀 상태 값 두 가지 상태가 출력되며, 이를 정의하기 위해, 입력 게이트(Input Gate), 출력 게이트(Output Gate), 잊음 게이트(Forget Gate)가 정의되어 기존의 재귀

신경망보다 매개 변수가 4 배 증가한다. 이를 이용하여, 긴 시간 스텝에서 멀리 떨어진 입력 값 간의 관계와 특성인자도 찾아낼 수 있다.

일반적으로 순차적인 데이터를 생성을 할 때는, 각 셀의 출력 값이 다음 셀의 입력 값으로 들어가는 자동회귀(Auto-Regression) 구조를 사용한다. 자동회귀 구조를 갖는 장단기 기억신경망을 이용하면, 긴 시간 스텝에도 강건한 신경망을 생성할 수 있으며, 각 셀의 출력 값을 정의한 5 가지의 연산의 색인 혹은 각 연산의 연결된 이전 상태의 색인으로 정의한다. 따라서, 각 블록마다 2 개의 연산이 있으므로 4 개의 셀이 정의되어야 하며, 4 개의 셀의 출력 값은 첫 번째 연산의 이전 상태 색인, 두 번째 연산의 이전 상태 색인, 첫 번째 연산의 색인, 두 번째 연산의 색인의 순서로 출력한다. 총 B 개의 블록이 있을 때 4B 개의 셀이 정의되며, 합성곱 셀 4B 개와 축소 셀의 4B 를 연속적으로 이어 총 8B 개의 셀을 가지며, 단 층의 장단기 기억신경망 구조를 사용하였다.

2.3 강화학습을 이용한 신경망 생성기 학습

생성된 신경망의 평가 셋의 정확도는 미분 불가능(Non-Differentiable)하기 때문에, 신경망 생성기의 매개변수를 학습할 수 없다. 따라서 강화학습을 이용하였고, 일반적으로 불연속적인 정책(Policy)을 근사하기 위해 신경망을 정의하고 정책을 바로 출력으로 하는 정책 목표 함수(Policy Object Function)를 정의한다. 그리고, 이 정책 목표 함수를 연속함수라 보고, 기존의 신경망을 확률적 기울기 강하(Stochastic Gradient Descent)를 이용하여 학습시키듯이, 정책 목표 함수의 기울기(Gradient)인 정책 기울기(Policy Gradient)를 한 에피소드(Episode)마다 계산하여 신경망의 매개변수를 학습하는 Monte-Carlo Policy Gradient 인 REINFORCE를 사용하였다. 이를 이용하여, 장단기 기억신경망을 정책 함수로 근사하였다. 강화학습의 상태(State)는 신경망 생성기의 매개변수에 의해 숨겨진 상태이며, 각 상태의 행동(Action) 셋은 위에서 언급한 연산의 구성요소를 포함하고 있고, 8B개 셀의 각 셀의 출력 값을 행동으로 취하고, 보상은 구성된 8B개에 의한 평가 셋의 정확도이다. 하지만 에피소드의 경로(Trajectory)가 길어질수록 보상의 편차(Variance)가 커지는 문제가 발생하기 때문에, Exponential Moving Average Baseline을 보상에서 빼 편차를 낮춘다. 최종적으로, 정책에 의해 하나의

에피소드가 정해지고 정확도를 보상으로 받으며, 정책 목표 함수에 대한 기울기를 구함으로써 높은 평가 셋 정확도를 만드는 방향으로 학습이 진행된다.

3. 실험 및 결과

3.1 데이터 설명

본 연구에서는 GE Bently Nevada 의 RK4 테스트베드에서 실제데이터를 얻어 테스트를 하였다. 고장 상태는 misalignment, rubbing, oil whirl 이 있다. 정상을 포함한 4가지 상태에 대해 5번 실험을 하여 총 5개의 셋을 얻었으며, 1번 셋에 대하여 평가를 수행하였다. 1 channel, 8500Hz로 진동 데이터를 취득하여 진동의 정보를 잃지 않는 최소한으로 7680Hz 로 Resampling을 하였다.

3.2 강화학습을 이용한 신경망의 효과

기준에 잘 알려진 모델을 이용했을 때 약 98%의 진단 정확도를 얻었지만, 강화학습을 이용하여 최적화된 신경망은 100%의 진단 성능을 얻었다. 기존에는 연구자의 시행착오를 통한 직관에 의존하여 네트워크를 구성하였다면, 본 연구에서는 강화학습으로 연구자의 시행착오를 대체하였다. 추가적으로, 데이터 셋이 큰 학습 모델은 강화학습으로 신경망을 찾는 과정이 오래 걸리므로, 데이터 특성은 유사하지만 크기가 작은 데이터 셋을 이용해 신경망을 찾은 후, 전이하면 효율적인 신경망 최적화가 가능하다.

4. 결 론

본 연구에서는 강화학습을 이용하여 주어진 RK4 테스트베드에서 얻은 진동 데이터에 적합한 합성곱 신경망 생성기를 개발하였다. 본 연구에서는 RK4 데이터 셋을 통해 유용성을 증명하였으며, 기 개발된 진동 데이터 기반의 합성곱 신경망 생성기를 이용한다면, RK4 데이터 셋 뿐만 아니라 진동 데이터 기반의 다른 데이터셋에서도 좋은 결과를 얻을 것이라 예측된다. 또한, RK4 데이터 셋에 최적화된 블록을 다양한 데이터 셋의 신경망에 전이하여 높은 정확도를 얻을 수 있을 것이라 예측된다.

후 기

본 연구는 한국전력공사 전력연구원의
연구과제(R17GA08)의 일환으로 수행되었습니다.

참고문헌

- (1) Yann LeCun, Yoshua Bengio, and Geoffrey Hinton,
2015, "Deep learning," Nature, Vol. 521, pp. 436~444
- (2) Hieu Pham, Melody Y. Guan, Barret Zoph, Quoc V.
Le and Jeff Dean, 2018, "Efficient Neural Architecture
Search via Parameter Sharing." arXiv preprint
arXiv:1802.03268